A3-2

言語処理学会第31回年次大会(NLP2025)

LLM マルチエージェント間の相互作用の分析

2025/03/11

東京大学
平野皓己, 何子軒,清水勇喜,陳曄,土井 智暉,谷中瞳

背景1 マルチエージェントLLMの有効性についての議論

複数のLLM エージェントがチームとして問題解決に取り組む**マルチエージェント(MA)** アプローチが盛んに研究されており、**MAがSAに比べて常に性能が向上するわけではないこと**が明らかになってきた

先行研究

- MA の方がシングルエージェント(SA) に比べ複雑なタスクにおける性能向上につながるという研究結果が複数 [Guo et al., 2024]
- 一方で、LLM 自体の推論能力やMA 自体の効果を疑問視する論文も存在
  - マルチエージェントはprompt engineeringしたシングルエージェントと同等性能 [Wang et al., 2024]

MAの問題解決能力がどういう条件でどのような理由で向上するのか不明

背景2 社会心理学とLLM研究の関係性

エージェント同士の相互作用とグループとしてのパフォーマンスの関連に関しては，社会心理学で長年研究されてきた。

LLM に対して有効な手法が，社会心理学で人間に対して既に発見されていた例

- （LLM）LLMが生成した回答をLLM自身が見直すことで，タスクの精度が向上する [Madaan et al., 2023]
- （社会心理学）人間のグループによる問題解決では，競合仮説を構築したり仮説の根拠を問いただしたりすることが重要である [Okada and Simon, 1997]

社会心理学がLLMエージェントの性能の分析に有効である可能性がある

Steiner's theory

複数人による課題解決のパフォーマンスについての理論

社会心理学において複数人による課題解決のパフォーマンスを説明する理論として、**Steiner's theory** がある [Steiner, 1972]

⇒ 多くの社会心理学の実験が支持 [Hill, 1982]

グループ全体のパフォーマンスに関する式

(Actual Group Productivity) = (Potential Productivity)
− (Productivity Losses) + (Productivity Gains)

Actual Group Productivity: 複数人での協力による効果
Potential Productivity: メンバーの能力、課題の特性などから決まる生産性
Productivity Losses / Gains: 潜在的生産性を下げる/上げる要因

研究の目的: Steiner’s theoryによるLLM相互作用の説明

Steiner’s theoryにおいて人間同士の相互作用によるパフォーマンスの変化を説明する**Productivity Losses・Gainsに着目**

Productivity Losses・Gains の中からLLMで
定量的に評価可能な項目を選定し、評価指標を定義

LLM同士の相互作用がパフォーマンスにどのように影響するのかを分析

Steiner's theoryに基づく評価指標

Productivity losses	**誤選択**	間違ったアイデアを別のエージェントが 選択する数
	誤生成	エージェントが間違った回答を生み出した数
	同意見	前のエージェントと同じアイデアが 繰り返される数
Productivity gains	**修正**	あるアイデアが別のエージェントによって 訂正された数
	新案	シングルエージェントの回答にはない、 新しい回答の数

対象としたタスクとMAフレームワーク

タスクとMAフレームワークは代表的なものを選定

タスク

- BBH (Causal Judgment) [Suzgun et al., 2022]: 200問を抜粋して使用
- GSM8K (Mathematical reasoning) [Cobbe et al. 2021]: 全187問を使用

エージェント構成

- シングルエージェント(SA)
- Cooperative [Du et al., 2023]：それぞれの回答が次のラウンドの各エージェントの入力に組み込まれ、2つのエージェントで会話して課題を解く。
- Competitive [Liang et al., 2024]：2人の参加者がある課題について対立する視点から議論することで、発散的思考を導入する。その後、ジャッジが入り、どちらの視点がより妥当か評価する。

※MAでは、それぞれの条件で2ラウンドの議論を行う。

予備実験: LLMによる評価の精度評価

本研究では、LLM (ChatGPT-4o) を使って各指標を検証
予備実験としてBBHデータセットから20問を選び、Cooperativeフレームワークの出力に対して、LLMと人間の評価値を比較
⇒**評価の傾向はおおよそ一致**

表1　事前実験における人間による評価値と GPT-4o による評価値の一致率 (%)

	正誤	誤選択	誤生成	同意見	修正	新案
BBH	95.0	95.0	85.0	60.0	75.0	85.0
GSM8K	100	100	90.0	85.0	90.0	85.0

誤選択の評価値と正誤は負の相関

MAによる意見の多様性は、正答を選ぶ能力に依存することを示唆: **Steiner's theoryと合致**

表 2 相関係数行列 (GSM8K-Cooperative-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.74	-0.05	-0.01	0.07
誤選択	-1.00	1.00	0.74	0.05	0.01	-0.07
誤生成	-0.74	0.74	1.00	-0.53	0.53	-0.00
同意見	-0.05	0.05	-0.53	1.00	-0.89	-0.07
修正	-0.01	0.01	0.53	-0.89	1.00	0.07
新案	0.07	-0.07	-0.00	-0.07	0.07	1.00

表 3 相関係数行列 (GSM8K-Competitive-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.59	0.27	-0.16	-0.30
誤選択	-1.00	1.00	0.59	-0.27	0.16	0.30
誤生成	-0.59	0.59	1.00	-0.57	0.56	0.52
同意見	0.27	-0.27	-0.57	1.00	-0.74	-0.49
修正	-0.16.	0.16	0.56	-0.74	1.00	0.54
新案	-0.30	0.30	0.52	-0.49	0.54	1.00

表 4 相関係数行列 (BBH-Cooperative-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.98	0.38	-0.17	-0.23
誤選択	-1.00	1.00	0.98	-0.38	0.17	0.23
誤生成	-0.98	0.98	1.00	-0.29	0.12	0.18
同意見	0.38	-0.38	-0.29	1.00	-0.76	-0.44
修正	-0.17	0.17	0.12	-0.76	1.00	0.42
新案	-0.23	0.23	0.18	-0.44	0.42	1.00

表 5 相関係数行列 (BBH-Competitive-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-0.94	-0.54	0.04	0.19	-0.14
誤選択	-0.94	1.00	0.54	-0.02	-0.21	0.10
誤生成	-0.54	0.54	1.00	-0.27	-0.26	0.11
同意見	0.04	-0.02	-0.27	1.00	-0.36	-0.38
修正	0.19	-0.21	-0.26	-0.36	1.00	0.49
新案	-0.14	0.10	0.11	-0.38	0.49	1.00

誤生成の評価値と正誤には大きな負の相関

誤った情報の伝搬がMAに悪影響を及ぼしていることを示唆: **Steiner's theoryと合致**

表 2 相関係数行列 (GSM8K-Cooperative-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.74	-0.05	-0.01	0.07
誤選択	-1.00	1.00	0.74	0.05	0.01	-0.07
誤生成	-0.74	0.74	1.00	-0.53	0.53	-0.00
同意見	-0.05	0.05	-0.53	1.00	-0.89	-0.07
修正	-0.01	0.01	0.53	-0.89	1.00	0.07
新案	0.07	-0.07	-0.00	-0.07	0.07	1.00

表 3 相関係数行列 (GSM8K-Competitive-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.59	0.27	-0.16	-0.30
誤選択	-1.00	1.00	0.59	-0.27	0.16	0.30
誤生成	-0.59	0.59	1.00	-0.57	0.56	0.52
同意見	0.27	-0.27	-0.57	1.00	-0.74	-0.49
修正	-0.16.	0.16	0.56	-0.74	1.00	0.54
新案	-0.30	0.30	0.52	-0.49	0.54	1.00

表 4 相関係数行列 (BBH-Cooperative-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.98	0.38	-0.17	-0.23
誤選択	-1.00	1.00	0.98	-0.38	0.17	0.23
誤生成	-0.98	0.98	1.00	-0.29	0.12	0.18
同意見	0.38	-0.38	-0.29	1.00	-0.76	-0.44
修正	-0.17	0.17	0.12	-0.76	1.00	0.42
新案	-0.23	0.23	0.18	-0.44	0.42	1.00

表 5 相関係数行列 (BBH-Competitive-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-0.94	-0.54	0.04	0.19	-0.14
誤選択	-0.94	1.00	0.54	-0.02	-0.21	0.10
誤生成	-0.54	0.54	1.00	-0.27	-0.26	0.11
同意見	0.04	-0.02	-0.27	1.00	-0.36	-0.38
修正	0.19	-0.21	-0.26	-0.36	1.00	0.49
新案	-0.14	0.10	0.11	-0.38	0.49	1.00

同意見の評価値は正誤と弱い正の相関または無相関

冗長な議論がグループの性能に悪影響を及ぼすという Steiner's theoryと相違

表 2 相関係数行列 (GSM8K-Cooperative-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.74	-0.05	-0.01	0.07
誤選択	-1.00	1.00	0.74	0.05	0.01	-0.07
誤生成	-0.74	0.74	1.00	-0.53	0.53	-0.00
同意見	-0.05	0.05	-0.53	1.00	-0.89	-0.07
修正	-0.01	0.01	0.53	-0.89	1.00	0.07
新案	0.07	-0.07	-0.00	-0.07	0.07	1.00

表 3 相関係数行列 (GSM8K-Competitive-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.59	0.27	-0.16	-0.30
誤選択	-1.00	1.00	0.59	-0.27	0.16	0.30
誤生成	-0.59	0.59	1.00	-0.57	0.56	0.52
同意見	0.27	-0.27	-0.57	1.00	-0.74	-0.49
修正	-0.16.	0.16	0.56	-0.74	1.00	0.54
新案	-0.30	0.30	0.52	-0.49	0.54	1.00

表 4 相関係数行列 (BBH-Cooperative-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.98	0.38	-0.17	-0.23
誤選択	-1.00	1.00	0.98	-0.38	0.17	0.23
誤生成	-0.98	0.98	1.00	-0.29	0.12	0.18
同意見	0.38	-0.38	-0.29	1.00	-0.76	-0.44
修正	-0.17	0.17	0.12	-0.76	1.00	0.42
新案	-0.23	0.23	0.18	-0.44	0.42	1.00

表 5 相関係数行列 (BBH-Competitive-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-0.94	-0.54	0.04	0.19	-0.14
誤選択	-0.94	1.00	0.54	-0.02	-0.21	0.10
誤生成	-0.54	0.54	1.00	-0.27	-0.26	0.11
同意見	0.04	-0.02	-0.27	1.00	-0.36	-0.38
修正	0.19	-0.21	-0.26	-0.36	1.00	0.49
新案	-0.14	0.10	0.11	-0.38	0.49	1.00

同意見の評価値と誤生成の評価値には負の相関

同意見が多く生じる事例においてはそもそも誤まった回答が生じない傾向にあった

→正解しやすい容易な問題において同意見が出やすかった可能性がある

表 2 相関係数行列 (GSM8K-Cooperative-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.74	-0.05	-0.01	0.07
誤選択	-1.00	1.00	0.74	0.05	0.01	-0.07
誤生成	-0.74	0.74	1.00	-0.53	0.53	-0.00
同意見	-0.05	0.05	-0.53	1.00	-0.89	-0.07
修正	-0.01	0.01	0.53	-0.89	1.00	0.07
新案	0.07	-0.07	-0.00	-0.07	0.07	1.00

表 3 相関係数行列 (GSM8K-Competitive-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.59	0.27	-0.16	-0.30
誤選択	-1.00	1.00	0.59	-0.27	0.16	0.30
誤生成	-0.59	0.59	1.00	-0.57	0.56	0.52
同意見	0.27	-0.27	-0.57	1.00	-0.74	-0.49
修正	-0.16.	0.16	0.56	-0.74	1.00	0.54
新案	-0.30	0.30	0.52	-0.49	0.54	1.00

表 4 相関係数行列 (BBH-Cooperative-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.98	0.38	-0.17	-0.23
誤選択	-1.00	1.00	0.98	-0.38	0.17	0.23
誤生成	-0.98	0.98	1.00	-0.29	0.12	0.18
同意見	0.38	-0.38	-0.29	1.00	-0.76	-0.44
修正	-0.17	0.17	0.12	-0.76	1.00	0.42
新案	-0.23	0.23	0.18	-0.44	0.42	1.00

表 5 相関係数行列 (BBH-Competitive-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-0.94	-0.54	0.04	0.19	-0.14
誤選択	-0.94	1.00	0.54	-0.02	-0.21	0.10
誤生成	-0.54	0.54	1.00	-0.27	-0.26	0.11
同意見	0.04	-0.02	-0.27	1.00	-0.36	-0.38
修正	0.19	-0.21	-0.26	-0.36	1.00	0.49
新案	-0.14	0.10	0.11	-0.38	0.49	1.00

修正・新案の評価値の正誤との相関は条件依存

条件によって弱い負の相関があるものから弱い正の相関があるものまでばらつきあり

修正・新案の効果はタスク・フレームワーク依存: Steiner's theoryと相違

表 2 相関係数行列 (GSM8K-Cooperative-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.74	-0.05	-0.01	0.07
誤選択	-1.00	1.00	0.74	0.05	0.01	-0.07
誤生成	-0.74	0.74	1.00	-0.53	0.53	-0.00
同意見	-0.05	0.05	-0.53	1.00	-0.89	-0.07
修正	-0.01	0.01	0.53	-0.89	1.00	0.07
新案	0.07	-0.07	-0.00	-0.07	0.07	1.00

表 3 相関係数行列 (GSM8K-Competitive-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.59	0.27	-0.16	-0.30
誤選択	-1.00	1.00	0.59	-0.27	0.16	0.30
誤生成	-0.59	0.59	1.00	-0.57	0.56	0.52
同意見	0.27	-0.27	-0.57	1.00	-0.74	-0.49
修正	-0.16.	0.16	0.56	-0.74	1.00	0.54
新案	-0.30	0.30	0.52	-0.49	0.54	1.00

表 4 相関係数行列 (BBH-Cooperative-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-1.00	-0.98	0.38	-0.17	-0.23
誤選択	-1.00	1.00	0.98	-0.38	0.17	0.23
誤生成	-0.98	0.98	1.00	-0.29	0.12	0.18
同意見	0.38	-0.38	-0.29	1.00	-0.76	-0.44
修正	-0.17	0.17	0.12	-0.76	1.00	0.42
新案	-0.23	0.23	0.18	-0.44	0.42	1.00

表 5 相関係数行列 (BBH-Competitive-4o)

	正誤	誤選択	誤生成	同意見	修正	新案
正誤	1.00	-0.94	-0.54	0.04	0.19	-0.14
誤選択	-0.94	1.00	0.54	-0.02	-0.21	0.10
誤生成	-0.54	0.54	1.00	-0.27	-0.26	0.11
同意見	0.04	-0.02	-0.27	1.00	-0.36	-0.38
修正	0.19	-0.21	-0.26	-0.36	1.00	0.49
新案	-0.14	0.10	0.11	-0.38	0.49	1.00

結論と今後の課題

結論: 人間において成立する法則が必ずしもLLMには適応できるとは限らない

- 実験の結果、**誤情報の伝播が性能に悪影響** を及ぼす可能性が示唆された
- Steiner’s theoryに反して、**冗長な議論は性能に悪影響を及ぼさなかった**
- **アイデアの修正や新案の提案といった相互作用の影響は、タスクやフレームワークの種類によって異なる** ことが明らかになった

今後の課題

指標やタスクの多様化、相互作用とパフォーマンスの因果関係についての分析、評価指標の自動計測精度の向上 など

参考：Productivity losses

Coordination Loss	グループ内の調整が不十分だと、遅延、誤解、不完全な情報共有が生じる。
Social Loafing	個々の貢献がグループの成果に大きな影響を与えないと感じると、メンバーは努力を減らす。
Production Blocking	ブレーンストーミングにおいて、メンバーが同時にアイデアを提供することが妨げられ、提案が忘れられたり、保留されたりする。
Decision-Making Bias	グループは、より良い解決策が存在する場合でも、不正確な情報に基づいて決定を下したり、声の大きいメンバーに従ったりすることがある。
Excessive Communication Time	非効率的な議論や無関係なコミュニケーションは、タスクの遂行を妨げる。
Misallocation of Resources	最も有能なメンバーからの貴重な意見が無視されたり、十分に活用されないことがある。

参考：Productivity gains

Pooling and Integration of Information	多様知識を共有し統合することで、個人で努力するよりも良い結果を導く。
Error Correction	グループメンバーがお互いのミスを特定し、修正することで、精度が向上する。
Aggregation of Resources	より大きなグループは、スキルやアイデアを組み合わせることができ、特に複雑なタスクに有益である。
Learning Effects	グループ活動は、メンバーのスキルや知識の向上に役立ち、それは将来の個人のパフォーマンスに反映される。
Risk Dispersion	グループはリスクを分散させ、個人が避けるような大胆な決断を可能にする。
Diverse Perspectives	異なる背景や専門知識を組み合わせることで、創造性と革新性が促進される。
Enhanced Motivation	他者の努力を観察することで、個人のモチベーションが高まる。
Improved Decision Accuracy	グループ内の誰かが正しい答えを見つけた場合、グループディスカッションによって正しい解決策が優勢になる可能性が高くなる。
Division of Labor	タスクをメンバー間で分担することで、効率と集中力を高めることができる。

参考：A Debate, MAD フレームワークのプロンプト

A.1 Debate

一人目のエージェントのプロンプトは以下のとおりである。

Can you double check that your answer is correct。

Put your final answer in the form (X) at the end of your response。

二人目のエージェントのプロンプトは以下のとおりである。

Using the reasoning from other agents as additional advice, can you give an updated answer?

Examine your solution and that other agents step by step。

最終決定エージェントのプロンプトは以下のとおりである。

You are a moderator。There will be two debaters involved in a debate competition。

They will present their answers and discuss their perspectives on the <debate topic>。

At the end of each round, you will evaluate both sides’ answers and decide which one is correct。

A.2 MAD

一人目のエージェントのプロンプトは以下のとおりである。

You are affirmative side。Please express your viewpoints。

二人目のエージェントのプロンプトは以下のとおりである。

You are negative side。You disagree with the affirmative side’s points。

Provide your reasons and answer。

ジャッジエージェントのプロンプト

You are a moderator。There will be two debaters involved in a debate competition。

They will present their answers and discuss their perspectives on the <debate topic>。

At the end of each round, you will evaluate both sides’ answers and decide which one is correc

参考：B 指標計測のためのプロンプト

″添付ファイルのマルチエージェントの会話から、以下について答えて。
・マルチエージェントの答えが合っていたら1、間違っていたら0 にしてください。複数の答えを出している場合は0 にしてください。過程も記載してください。:
・会話中に正解があったにもかかわらず、最終結果が正解と違ったアイデアを選んでいたら1 にしてください。誰も正しい答えを出せていなかった場合は0 にしてください。答えが正解の場合は必ず0 になります。:
・正解と照らし合わせて、正解と違ったメッセージの数（最後のジャッジは除く）を教えてください。その数をカウントする過程も記載してください。:
・teammate_1（１回目）のメッセージとteammate_1（２回目）のメッセージ、及び、teammate_2（１回目）のメッセージとteammate_2（２回目）のメッセージが、Yes、No の回答だけでなく、その回答に至る根拠の説明も含めてまったく同じだった数を教えてください。その回答に至る根拠の説明も同じ場合だけカウントしてください。その数をカウントする過程も記載してください。:
・前のエージェントの間違った答えを次のエージェントが正しく修正した数を教えてください。その数をカウントする過程も記載してください。:
・シングルエージェントのアイディアと、マルチエージェントのアイディアをそれぞれ日本語でリストアップしてください。マルチエージェントのアイディアで重複するものがあれば削除してください。シングルエージェントのアイディアと、重複削除後のマルチエージェントのアイディアで似ているものをカウントしてください。似ていないもの（マルチエージェントのアイディアのみ）もカウントしてください。
最後にカウントした結果を箇条書きで書いてください。
###会話のテーマ###
{query}
###正解###″
{right_answer}
###シングルエージェントの会話###
{single_agent_answer}
###マルチエージェントの会話###
{multi_agent_answer}